AVANCE PI14 — Análisis e interpretación de resultados

GRUPO B · APORTE PRÁCTICO / SOFTWARE

Desarrollo de Proyecto de Tesis II — Sección G6 — 2026-II

Campo	Información
Código de tesis	T2
Tesista	Cam Zhong, Paulina Jiaqi
Título de la tesis	Predicción de defectos en software mediante algoritmos de Machine Learning para mejorar el aseguramiento de calidad en proyectos de desarrollo
Grupo	B — Aporte práctico / software
Artefacto	PDS-QA: Streamlit con inferencia E6_ADASYN_MI y pipeline experimental para priorización por esfuerzo
Fecha de este avance	09/11/2026 (corte de evidencias locales; sellos UTC 10/11)
Repositorio	https://github.com/Paulinaczz/T2_Cam_Zhong_Paulina_Jiaqi (no se ha verificado en este informe la publicación del ZIP nuevo en GitHub)
Evidencias recibidas	T2_CPDP_Resultados_y_Evidencias.zip; validacion_local.zip; 11 capturas originales recibidas el 10/11/2026 (8 Streamlit, 3 CSV/Excel).
Campo	**Información**
Hipótesis general	La tesis proporcionada no contiene una hipótesis general formal y literal identificable. Para este análisis se contrasta operacionalmente la expectativa de que la priorización ML mejore a ManualUp bajo presupuesto LOC. NO se atribuye esta formulación como cita de una hipótesis aprobada.
Repositorio / análisis	https://github.com/Paulinaczz/T2_Cam_Zhong_Paulina_Jiaqi (publicación de evidencia no comprobada). Archivos adjuntos: T2_CPDP_Resultados_y_Evidencias.zip y validacion_local.zip.
Alcance interpretativo	Análisis descriptivo y exploratorio de cinco proyectos sobre datos históricos; no es una validación independiente sobre un sexto proyecto ni un estudio con usuarios.

ACTUALIZACIÓN CON EVIDENCIAS. Este informe incorpora resultados experimentales de cinco proyectos y pruebas locales del artefacto E6: 7/7 casos funcionales/seguridad aprobados en backend, pytest 14/14 y CP06 con 30 repeticiones para 18 módulos y 30 para JM1 completo (13 204). La estrategia probabilidad/LOC se incorporó tras conocer el desempeño previo frente a ManualUp y sigue siendo exploratoria. No hay capturas de UI ni sesiones con usuarios. Los sellos UTC del 10/11/2026 corresponden a la noche del 09/11/2026 en Perú.

Parte 0 — Seguimiento de observaciones pendientes

N.º	Origen	Observación pendiente	Acción comprobada / por completar	Cap. / evidencia	Estado
01	Parcial P1 / PI11 O1	El modelo no acredita mejora consistente frente a ManualUp bajo presupuesto LOC.	Se ejecutó E6 con calibración en proyectos fuente y ranking probabilidad/LOC; 29,09 % vs 28,74 %; Δ positivo en 2/5, cinco IC incluyen cero.	PI13 §2.3 / PI14 §2.3; ZIP estrategia_esfuerzo	En proceso
02	Parcial P2 / PI11 O3	Duplicados, 121 grupos con etiquetas contradictorias y procedencia NASA/PROMISE.	17 442→11 690; cero solapamientos; política principal sin consultar etiqueta y sensibilidad a 11 569. Falta justificar fuente y versión en tesis.	ZIP auditoria/resumen_cohortes.json; fuentes_y_sha256.csv	En proceso
03	Parcial P3	Integración E6 y coherencia entre experimento, app y tesis.	El asesor verificó E6 y 14 pruebas en merge 76a4786 (02/11); falta reflejar modelo definitivo y sensibilidad E6/E7 en tesis. Prueba local reciente: 14 passed (09/11).	Revisión 02/11; validacion_local.zip/suite_pytest.txt	En proceso documental
04	Parcial P4	Comparación no homogénea de algoritmos/base y falta de informe científico.	Existen comparaciones SVM/RF/XGBoost y SVM base vs final; falta incorporar tablas a capítulo de resultados con protocolo identificado.	ZIP comparacion_algoritmos_referencia_previa.csv	En proceso documental
05	Parcial P5 / PI11 O8	Las 21 métricas se ingresan precalculadas; no se demuestra extracción ni transferencia real.	Se reconoce alcance de entrada precomputada; falta extracción demostrativa o delimitación explícita en tesis/conclusiones.	PI11+PI12 §1.1 y §2.6	En proceso
06	Parcial P6	Video narrado de 5–8 min, Anexo B, referencias y consistencia de figuras.	El video previo de 2:14 no satisface el requisito; falta una nueva grabación y subsanar anexos y citas.	Revisión PI9+PI10, §2	Pendiente
07	PI9+PI10 / PI11 O4	OE2 y metodología todavía describen 80/20; sistema usa LOPO anidado.	Plan y experimento emplean LOPO; actualizar tesis y OE2 previa coordinación del asesor.	PI11+PI12 §1.2; tesis caps. III y V	En proceso
08	PI9+PI10	E3 historial/exportación no prueba por sí solo OE4.	PI11 asigna CP07 a OE4 y vincula historial con trazabilidad general; falta actualizar tesis/demostración.	PI11+PI12 §2.3; PI13 §1.2	En proceso
09	PI11 O2	Wilcoxon bilateral n=5 no puede alcanzar p<0,05 en caso extremo.	Reporte por proyecto, mediana, 2/5 deltas positivos, bootstrap de 1 000 remuestreos; p bilateral 0,8125 solo exploratorio. Falta corregir plan/tesis.	PI14 §3.2–3.3; ZIP IC95_por_proyecto.csv	En proceso

N.º	Origen	Observación pendiente	Acción comprobada / por completar	Cap. / evidencia	Estado
10	PI11 O5	Metas de conteo no demuestran calidad; faltan referencias F1/AUC/AP.	Se informan F1/AUC/AP como antecedentes; falta formalizar metas de calidad comparables y justificadas.	PI11+PI12 §1.2; ZIP referencias previas	Pendiente
11	PI11 O6	≥30 repeticiones con JM1 completo y separación de validación e inferencia.	Se ejecutaron 30 mediciones por lote (18 y 13 204). p95 inferencia: 0,0767 s y 50,50 s; la meta de 5 s solo aplica a 18 filas. Sin captura UI.	validacion_local.zip/casos/CP06/resumen_cp06.csv	En proceso; medición hecha
12	PI11 O7	I-05 sin juicio de 2–3 jueces; tareas equivalentes de referencia sin concretar.	No constan fichas de jueces ni sesiones; CP10 se declara no ejecutado.	PI13 §1.3; PI14 §3.4	Pendiente
13	PI11 O9	Carpetas [CREAR] y fechas de piloto pendientes.	Carpeta de evidencia local creada; falta acceso público/verificable y fechas de usabilidad.	validacion_local.zip/entorno.json	En proceso

El estado es documental y conservador: no atribuye aprobación del profesor ni páginas de tesis que todavía no se han actualizado. Se incluyen observaciones parcialmente atendidas porque falta cerrar su evidencia.

Parte 1 — Procesar resultados

1.1 Preparación de los datos

Campo	Información
Fuente de los datos	a) Investigación: T2_CPDP_Resultados_y_Evidencias.zip, cinco proyectos. b) Validación del artefacto local: validacion_local.zip, registro_casos.json, suite_pytest.txt, casos/CP06/mediciones_cp06.csv y resumen_cp06.csv.
Depuración	17 442 registros originales; deduplicación global de las 21 características sin consultar etiqueta para seleccionar representante: 11 690. Se identifican 121 grupos de etiquetas contradictorias, con 1 610 filas originales afectadas. Sensibilidad: 11 569.
Consolidación	Un fold por proyecto objetivo; comparación con presupuesto de módulos completos, LOC=max(LOC,1). Se calcularon medias macro de igual peso, cinco diferencias E6−ManualUp y 1 000 réplicas bootstrap por proyecto.
Herramientas	Evaluación científica: Python, pandas, scikit-learn, imbalanced-learn; bootstrap. Pruebas locales: Windows 10; Python 3.13.0, sklearn 1.6.1, imblearn 0.14.2, pytest 9.1.1, Streamlit 1.65.0; SHA E6 verificado.

Campo	Información
Archivo de análisis	Experimento: scripts CSV/JSON en T2_CPDP_Resultados_y_Evidencias.zip. Backend/CP06: validacion_local.zip/casos/CP06/resumen_cp06.csv y registro_casos.json.
Control de calidad	Los 10 pares de proyectos tienen solapamiento exacto de vectores X igual a cero; el proyecto de prueba no alimenta la calibración. El bootstrap condicional no recoge incertidumbre de reentrenamiento.

1.2 Estadística descriptiva por indicador

Indicador	Grupo/condición	n	Media	Mediana	DE	Mín. – Máx.
Recall@20 % LOC	E6 calibrado / LOC	5	29,09 %	25,71 %	7,59 pp	21,43 % – 38,19 %
Recall@20 % LOC	ManualUp	5	28,74 %	27,14 %	8,35 pp	19,57 % – 39,16 %
Δ Recall@20 % LOC	E6 – ManualUp	5	0,36 %	-0,97 %	2,40 pp	-1,43 % – 4,35 %
Validación CSV (s)	18 módulos	30	0,030	0,030	0,003	0,027 – 0,037
Inferencia E6 (s)	18 módulos	30	0,070	0,070	0,005	0,063 – 0,085
Total medido (s)	18 módulos	30	0,101	0,100	0,006	0,091 – 0,112
Validación CSV (s)	JM1 (13 204 módulos)	30	0,468	0,468	0,034	0,421 – 0,555
Inferencia E6 (s)	JM1 (13 204 módulos)	30	48,890	49,528	1,686	44,672 – 51,081
Total medido (s)	JM1 (13 204 módulos)	30	49,358	49,999	1,695	45,178 – 51,562

Las estadísticas se calculan sobre cinco proyectos (no sobre 11 690 registros independientes). La desviación estándar de las diferencias se expresa en puntos porcentuales.

1.3 Tablas y figuras de resultados

N.º	Tabla / figura	Contenido	Archivo fuente
T1	Comparación por proyecto	Recall@20 % LOC E6/ManualUp, delta e IC por proyecto	02_resultados/ estrategia_esfuerzo/ principal_deduplicada/ diferencias_20pct_LOC_por_proyecto.csv
T2	Resumen macro	Presupuestos LOC y módulos, Popt	02_resultados/ estrategia_esfuerzo/ principal_deduplicada/ resumen_macro_por_metodo_y_presupuesto.csv
F1	Curvas de recuperación	Recall acumulado según fracción de LOC	02_resultados/ estrategia_esfuerzo/ principal_deduplicada/ curvas_recall_LOC.png
F2	Diferencia e IC bootstrap	Cinco deltas E6−ManualUp con incertidumbre condicional	02_resultados/ estrategia_esfuerzo/ principal_deduplicada/ delta_por_proyecto_IC95.png
4	Tabla 4. CP06: tiempos por tamaño de lote	30 repeticiones por lote, fases separadas	validacion_local.zip/ casos/CP06/

N.º	Tabla / figura	Contenido	Archivo fuente
			resumen_cp06.csv
5	Tabla 5. Validación funcional backend	7 casos pasaron; pytest 14 aprobadas	validacion_local.zip/ registro_casos.json

Figura 1. Recall acumulado frente a esfuerzo LOC

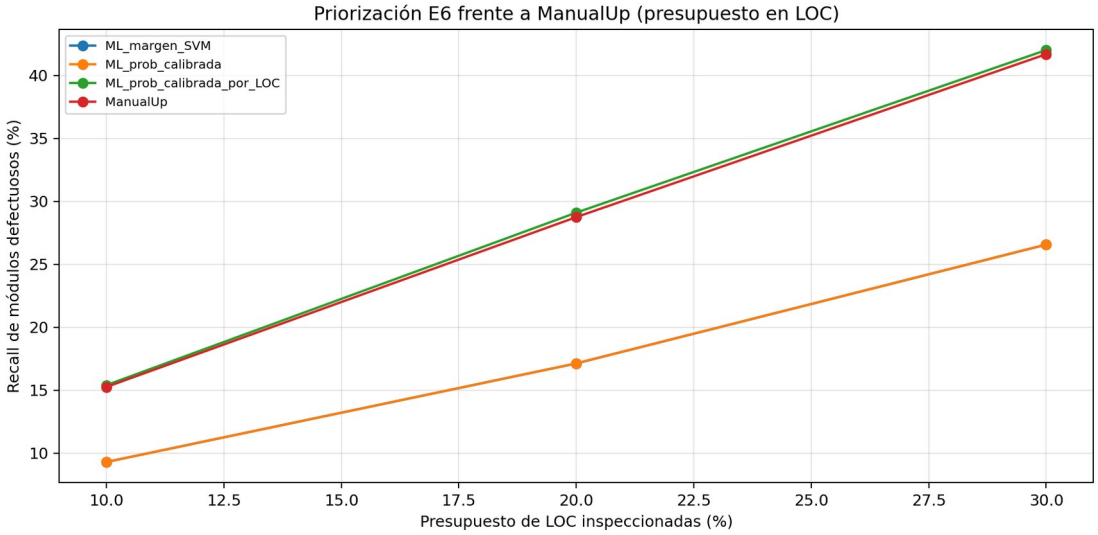
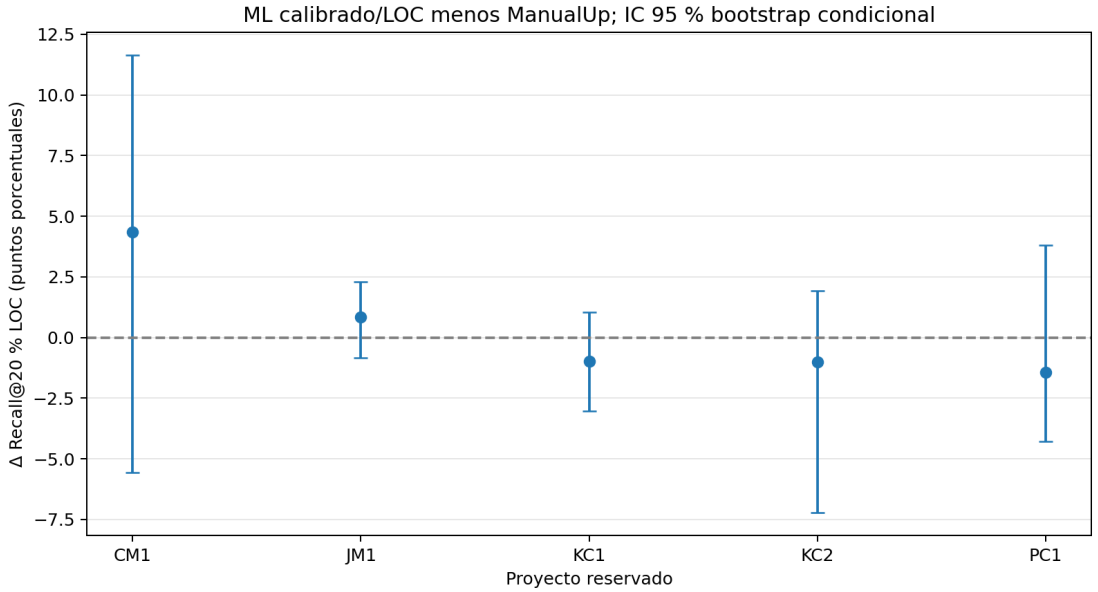


Figura 2. Diferencias con intervalos bootstrap por proyecto



Fuente de ambas figuras: ZIP experimental recibido el 09/11/2026. No implican validación independiente ni equivalencia de costos LOC con tiempo humano.

Parte 2 — Comparar con criterios y objetivos

2.1 Indicadores frente a la meta

OE	Criterio	Indicador	Meta / condición	Valor obtenido	Brecha / veredicto
OE1	Sustento	Familias SVM/RF/XGBoost	3 fuentes metodológicas; calidad a justificar	3 familias documentadas	Parcial
OE2	Limpieza / LOPO	Vectores duplicados entre proyectos	Solapamiento = 0	0 en todos los pares	Cumple subindicador

OE	Criterio	Indicador	Meta / condición	Valor obtenido	Brecha / veredicto
OE3	FS y ML	27 configs; métricas predictivas	Reproducibilidad, calidad comparativa pendiente	Resultados de referencia existentes, sin corrida nueva CP09	No evaluado formalmente
OE4	Ranking con costo	Recall@20 % LOC vs ManualUp	PI11: Δ media >0 para alegar mejora; asesor exige consistencia	29,09 % vs 28,74 %; +0,36 pp; 2/5 Δ>0	Ventaja media leve; mejora no demostrada
OE4	Ranking con costo	Popt normalizado 0–20	Comparación secundaria frente a ManualUp	0,2550 vs 0,2571	−0,0021: ManualUp mayor
OG	Calidad funcional	CP01–CP05, CP11–CP12	Casos críticos en backend, UI pendiente	7/7 backend y 14/14 pytest; 8 capturas UI + 3 CSV; CP01/CP05 corroborados visualmente, capturas de rechazos pendientes	Cumple backend; parcial integral
OG	Rendimiento y usabilidad	CP06 y CP10	CP06 p95 ≤5 s (18 filas); ≥30 repeticiones; CP10 validado por jueces	CP06: 18 p95 0,0767 s; JM1 p95 50,50 s; CP10 no ejecutado.	Cumple CP06 18 filas; CP10 no evaluado

2.2 Logro de objetivos específicos

OE	Enunciado (síntesis fiel)	Nivel de logro	Justificación sustentada
OE1	Revisar literatura: tendencias, algoritmos y desafíos	Parcial	Cuadro de antecedentes y referencias SVM, RF, XGBoost disponibles; síntesis final con criterios de calidad aún pendiente.
OE2	Implementar preprocesamiento NASA/PROMISE	Parcial	Deduplicación y LOPO verificables; texto vigente de tesis aún dice 80/20 y falta coordinar rectificación.
OE3	Seleccionar características y entrenar SVM/RF/XGBoost	Parcial	Comparaciones y 27 escenarios históricos disponibles; no se reejecutó CP09 completo en este avance.
OE4	Evaluar modelos y demostrar mejora frente a enfoques tradicionales	No demostrado	La diferencia macro a 20 % LOC es +0,36 pp, pero 2/5 proyectos y cinco IC cruzan cero; Popt@20 favorece levemente ManualUp.
OG	Desarrollar y evaluar PDS-QA en tareas reales de QA	Parcial	7/7 backend; 14/14 pytest; p95 18 filas=0,0767 s y JM1=50,50 s; UI01–UI06 con recorrido positivo; faltan UI negativa y CP10.

2.3 Contraste con la línea base

Métrica	ManualUp	Artefacto	Δ absoluta	Mejora relativa*	Interpretación
Recall@10 % LOC	15,25 %	15,39 %	+0,15 pp	+0,96 %	Diferencia pequeña; indicador secundario.

Métrica	ManualUp	Artefacto	Δ absoluta	Mejora relativa*	Interpretación
Recall@20 % LOC	28,74 %	29,09 %	+0,36 pp	+1,24 %	Solo 2 de 5 proyectos son positivos; no demuestra mejora consistente.
Recall@30 % LOC	41,68 %	42,00 %	+0,33 pp	+0,79 %	Ventaja pequeña con otro presupuesto de inspección.
Popt normalizado 0–20	0,2571	0,2550	−0,0021	−0,82 %	Bajo el área de curva, ManualUp supera ligeramente al ML.
Recall@20 % módulos	6,24 %	6,46 %	+0,22 pp	+3,64 %	Costo por número de módulos; NO sustituye costo por LOC.

** La mejora relativa es (artefacto − línea base) / línea base; usar las cifras sin redondear para los cálculos. «Puntos porcentuales» no son lo mismo que «porcentaje de mejora relativa».*

Tabla de diferencias a 20 % LOC e intervalos

Proyecto	ManualUp	E6 prob./LOC	Δ	IC95 bootstrap de Δ (pp)	Δ>0
CM1	19,57 %	23,91 %	+4,35 pp	[-5,56; 11,63]	Sí
JM1	35,37 %	36,22 %	+0,85 pp	[-0,83; 2,30]	Sí
KC1	39,16 %	38,19 %	-0,97 pp	[-3,04; 1,06]	No
KC2	22,45 %	21,43 %	-1,02 pp	[-7,22; 1,92]	No
PC1	27,14 %	25,71 %	-1,43 pp	[-4,29; 3,80]	No

Parte 3 — Aplicar estadística

3.1 Hipótesis estadísticas operativas

Campo	Información
H0	Diferencia de rendimiento entre E6/LOC y ManualUp igual a cero en la distribución de los cinco pares (hipótesis nula exploratoria para Wilcoxon bilateral).
H1	La distribución de diferencias pareadas no está centrada en cero (contraste bilateral exploratorio).
α y criterio	α = 0,05 se presenta como umbral de referencia exploratoria, NO como condición suficiente ni alcanzable para declarar mejora con Wilcoxon bilateral exacta de cinco pares; el asesor solicita considerar consistencia y bootstrap por proyecto.

3.2 Verificación de supuestos

Supuesto	Evaluación	Estadístico / p	Conclusión
Pares comparables	ManualUp y E6 evaluados en los mismos proyectos y mismo presupuesto	5 pares	Apareamiento adecuado al contraste descriptivo.
n suficiente	Wilcoxon bilateral exacto n=5, mínimo p=0,0625	n=5	No puede alcanzar p<0,05, aun con todos los signos favorables.
Independencia entre proyectos	Cinco datasets relacionados con NASA y limpieza global	No verificable plenamente	Amenaza a la validez de conclusión y externa.
Intervalos de diferencias	Bootstrap 1 000 remuestreos de módulos por proyecto	5 intervalos cruzan cero	IC condicional en puntuaciones entrenadas; no evalúa variación entre nuevos proyectos.
Normalidad	No se requiere para Wilcoxon; n=5 no respalda chequeo robusto	No se realizó Shapiro formal	Evitar seleccionar pruebas a posteriori por un test inestable.

3.3 Resultados de la prueba de hipótesis

Hipótesis / OE	Prueba	Estadístico	p	Tamaño del efecto	IC95 %	Decisión
Comparación pareada / OE4	Wilcoxon bilateral exacta (exploratoria)	W = 6, n = 5	0,8125	Δ media = +0,36 pp; mediana = −0,97 pp; 2/5 favorables	Por proyecto: 5/5 incluyen 0	No se rechaza H0; no es equivalencia ni superioridad
Criterio exploratorio de consistencia / OE4	Conteo de signos e IC bootstrap	2/5 deltas > 0	No corresponde	Máx. +4,35 pp; mín. −1,43 pp	0/5 excluyen 0	No cumple criterio de consistencia

El p = 0,8125 se recalculó sobre las cinco diferencias contenidas en el CSV de evidencias. Un p grande no prueba equivalencia. La media Δ fue +0,3559 puntos porcentuales y su mediana −0,9709 pp; los números se redondean para presentar.

3.4 Confiabilidad de instrumentos aplicados

Instrumento	n	Coeficiente	Interpretación
I-05 (encuesta piloto ad hoc)	0 sesiones verificadas	No aplica	Sin juicio previo de 2–3 jueces, no calcular alfa ni declarar instrumento validado.
I-02 (auditoría cuantitativa)	5 proyectos	No aplica (no es cuestionario)	Reproducibilidad técnica mediante CSV/JSON y hashes; no equivale a fiabilidad psicométrica.

Parte 4 — Interpretación y discusión

4.1 Hallazgos principales

N.º	Hallazgo	Dato que lo respalda	OE
1	La estrategia E6 calibrada/LOC mejora la media del recall bajo el 20 % de LOC en magnitud mínima.	29,09 % vs 28,74 %; Δ = +0,36 pp	OE4
2	La ganancia no es consistente entre proyectos.	2/5 positivos; 5/5 IC bootstrap incluyen cero	OE4
3	La clasificación por margen sin ajuste por LOC es inadecuada frente a ManualUp con este costo.	E6 margen 17,12 % vs ManualUp 28,74 %	OE4
4	Popt no confirma la ventaja observada en Recall@20 % LOC.	Popt@20: 0,2550 vs 0,2571 (ManualUp)	OE4
5	Se redujeron duplicados entre proyectos, pero persistieron decisiones sobre etiquetas y procedencia.	17 442→11 690; 121 grupos contradictorios; cero solapamiento	OE2

4.2 Contraste con los antecedentes

Antecedente (citado en PI11+PI12)	Aporte metodológico referido	Resultado de esta investigación	Coincidencia / diferencia y alcance
Mende y Koschke (2010)	Modelos de predicción conscientes del esfuerzo; costo de inspección explícito.	E6 probabilidad/LOC: 29,09 %; ManualUp: 28,74 % a 20 % LOC.	Coincide en evaluar costo; no se afirma comparación cuantitativa directa sin datos/protocolo homogéneos.
Kamei et al. (2013)	Priorización de defectos de acuerdo con recursos y esfuerzo.	La densidad de riesgo mejora respecto a E6 margen, pero no de forma consistente ante ManualUp.	Coherencia metodológica con riesgo/LOC; datasets y unidades de análisis pueden ser distintos.
Zhou et al. (2018)	Importancia de comparar estrategias simples exigentes en escenarios de esfuerzo.	ManualUp supera en 3/5 proyectos y tiene Popt@20 ligeramente mayor.	La línea base fuerte sigue competitiva; no se sostiene superioridad general del ML.

Estos antecedentes están citados en el documento PI11+PI12 y en la revisión docente. No se inventan valores numéricos de los artículos; comparar directamente métricas requeriría recuperar protocolos, datasets y definiciones equivalentes.

4.3 Limitaciones y amenazas a la validez

Limitación / amenaza	Tipo	Efecto sobre resultados	Mitigación / reporte
Cinco proyectos y ningún sexto proyecto independiente	Externa / conclusión	No generalizar mejora a proyectos nuevos; poca capacidad inferencial.	LOPO y reporte de 5 diferencias, necesidad de confirmación futura.
Estrategia propuesta después de ver resultados adversos	Conclusión	Riesgo de selección post hoc de métrica/estrategia.	Declarar análisis adicional exploratorio y no reemplazar la métrica original.
Calibración con proyectos fuente, sin etiquetas del objetivo	Interna / constructo	Probabilidades sujetas a cambios de distribución entre proyectos.	OOF de fuentes, Brier por proyecto y reserva completa de target.
121 grupos con etiquetas contradictorias	Interna / constructo	Resultados sensibles a política de limpieza.	Principal sin consultar etiquetas; sensibilidad secundaria; certificar procedencia.
LOC como sustituto de esfuerzo humano	Constructo	No permite asegurar horas o costos reales de QA.	Reportar presupuestos LOC y módulos por separado.
Bootstrap de módulos, predicciones fijas	Conclusión	IC omite incertidumbre por reentrenamiento y nuevos proyectos.	Explicar interpretación condicional.
Prototipo no extrae 21 métricas desde código fuente	Externa / constructo	Uso real exige herramienta previa de métricas.	Declarar alcance y mostrar extracción demostrativa.
Sin capturas de rechazos negativos UI y sin estudio CP10	Interna / externa	El backend está probado, pero hay evidencia visual del flujo positivo, pero no de rechazos negativos en UI ni de usuarios.	CP01–CP06/CP11–CP12 acreditados en backend; CP06 con 60 mediciones. Completar capturas adversarias de UI y validar I-05 por jueces antes de CP10.

Parte 5 — Matriz de coherencia: objetivo → resultado → conclusión

OE/hipótesis	Indicador / meta	Resultado	Prueba / decisión	¿Logrado?	Conclusión preliminar
OE1	Revisión de 3 algoritmos con sustento	SVM, RF, XGBoost referenciados	Auditoría documental parcial	Parcial	El análisis teórico sustenta la experimentación, pero falta cierre bibliográfico.
OE2	Deduplicación, 0 solapamiento	11 690 registros; 0 solapamientos	Auditoría reproducible; origen pendiente	Parcial	Se reduce un sesgo por duplicación; persisten problemas de etiquetas/procedencia.
OE3	Clasificadores y FS; calidad predictiva	Resultados históricos disponibles	Falta nueva verificación completa CP09	Parcial	Se implementaron y compararon familias de modelos; metas de calidad deben formalizarse.
OE4 / H0-H1 operativas	Δ Recall@20 % LOC y consistencia frente a ManualUp	+0,36 pp macro; 2/5 positivos	Wilcoxon p=0,8125 exploratoria; IC incluyen 0	No demostrado	La densidad de riesgo no demuestra superioridad consistente bajo costo LOC.

OE/hipótesis	Indicador / meta	Resultado	Prueba / decisión	¿Logrado?	Conclusión preliminar
OG	Artefacto funcional; meta p95 ≤5 s en 18 filas; usabilidad pendiente	7/7 backend; 14/14 pytest; CP06 p95=0,0767 s en 18 filas; 8 capturas UI + 3 Excel; JM1 50,50 s	Cumple backend y tiempo para 18 filas; UI positiva corroborada; negativa/CP10 no evaluadas	Parcial	El núcleo funciona y hay evidencia visual del flujo positivo, pero siguen pendientes las pruebas de rechazo en interfaz y la usabilidad CP10; no se ha demostrado superioridad consistente frente a ManualUp.

Lista de verificación antes de enviar

☐ Datos y estadística descriptiva calculados sobre los CSV adjuntos.

☐ Líneas base, diferencias, IC y p exploratorio explicitados.

☐ Hallazgos negativos y limitaciones declarados sin ocultamientos.

☐ NO se registra una hipótesis general literal no hallada en tesis; se requiere coordinación con asesor.

☑ CP06 ejecutado y medido en dos lotes. ☐Falta validar I-05, ejecutar CP10 y publicar las evidencias en un enlace accesible.

 Falta actualizar capítulos V–VI y confirmar metas revisadas con asesor.

Distribución de responsabilidades

No aplica: tesis individual T2. Responsable del análisis: Cam Zhong, Paulina Jiaqi.

Fuentes documentales y localización de evidencias

• Plantilla_PI13_Grupo_B.pdf y Plantilla_PI14_Grupo_B.pdf (modelos de apartados y tablas).

• T2_PI11-PI12_Cam_Zhong_Paulina_Jiaqi.docx (OE, instrumentos I-01–I-06, CP01–CP12, metas y base ManualUp).

• T2_Cam_Zhong_Revision_PI11_PI12.docx (observaciones O1–O9, 02/11/2026).

• T2_Cam_Zhong_Revision_PI9_PI10.docx y Bloque1_Observaciones_Parcial_Semana10_CONSOLIDADO.pdf (observaciones anteriores).

• T2_CPDP_Resultados_y_Evidencias.zip (CSV/JSON y figuras experimentalmente generados el 09/11/2026).

• Tesis - Cam Zhong Paulina Jiaqi.docx (objetivos textuales; conserva metodología 80/20 y requiere actualización).

ANEXO — Resultados complementarios de pruebas locales

Los tiempos siguientes proceden de validacion_local.zip (mediciones originales y resumen CSV), sobre el modelo E6 en Windows 10, commit 76a4786f638ba5fae248d100ae2b6310e86905a2. Se excluye el arranque y la persistencia en los tiempos de CP06; el criterio p95 ≤5 s se definió para el lote de 18 filas, no para JM1 completo. Fechas de las pruebas locales: 09/11/2026, entre 23:27 y 23:54 (hora de Lima, UTC−05:00); los logs muestran 10/11/2026 a las 04:27–04:54 UTC. Fuente: validacion_local.zip/ejecucion.log.

Lote	Fase	n	Media (s)	Mediana (s)	p95 (s)	Criterio
JM1 completo	validacion	30	0,468	0,468	0,525	No fijado
JM1 completo	inferencia	30	48,890	49,528	50,497	No fijado
JM1 completo	total	30	49,358	49,999	51,019	No fijado
ejemplo 18	validacion	30	0,030	0,030	0,035	No fijado
ejemplo 18	inferencia	30	0,070	0,070	0,077	Cumple
ejemplo 18	total	30	0,101	0,100	0,111	No fijado

Rendimiento: con 18 registros, el p95 de inferencia es 0,0767 s y el p95 total medido es 0,1108 s. Con JM1 (13 204 registros), el p95 de inferencia asciende a 50,50 s. En ambos lotes se midió validación CSV e inferencia por separado. No existe un objetivo de tiempo de referencia comparable (antes/después) para el lote JM1.

Las siete comprobaciones CP01–CP05, CP11–CP12 reportaron APROBADO_BACKEND y pytest completó 14 pruebas aprobadas. El 10/11/2026 se añadieron 8 capturas de Streamlit y 3 CSV/Excel. Corroboran CP01/CP05 y exportación normal, pero no rechazos negativos, ataque de fórmula ni bloqueo visual de hash; la validación integral sigue parcial.

Evidencias: validacion_local.zip/registro_casos.json; casos/CP06/mediciones_cp06.csv; casos/CP06/resumen_cp06.csv; suite_pytest.txt; entorno.json; modelo_validado.json.

ADENDA — Evidencia visual recibida el 10/11/2026

Se incorporan 8 capturas de las vistas UI01–UI06 de Streamlit y 3 capturas de los CSV abiertos en Excel. Las imágenes son posteriores a la ejecución automática local del 09/11/2026 y no acreditan una ejecución retroactiva de interfaz.

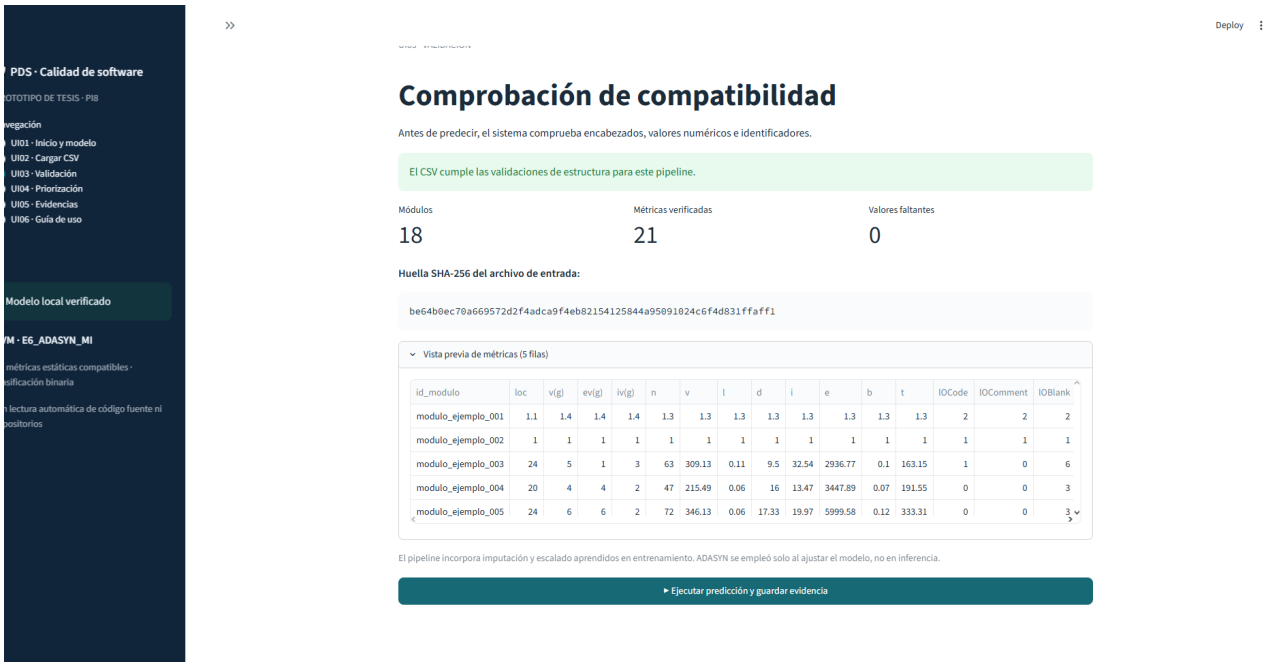
Las capturas demuestran el recorrido positivo de CP01 y CP05; para CP02, CP03, CP11 y el caso adversario de CP04 y CP12 siguen siendo necesarios los logs de backend y, si se exige prueba integral de interfaz, las capturas negativas. No se confunden capturas con pruebas independientes.

ID / pantalla	Verificación visual	Caso y alcance
EVV01 — UI01 Inicio y modelo	SVM E6_ADASYN_MI, 21 métricas; lectura responsable del score.	CP01 / CP12 informativo / OG. Límite: No acredita ataque a integridad ni rendimiento.
EVV02 — UI02 Formulario de carga	Selector de archivos CSV y acceso a plantilla/ejemplo.	CP01 preparación. Límite: No demuestra carga ni predicción por sí sola.
EVV03 — UI02 Archivo cargado	Se observa el archivo ejemplo_carga (1).csv listo para validar.	CP01. Límite: No prueba entradas adversarias.
EVV04 — UI03 Validación	CSV válido: 18 módulos, 21 métricas, 0 faltantes; SHA-256 del archivo.	CP01 / OE3 / OG. Límite: No es una prueba de rechazo de CSV inválido.
EVV05 — UI04 Ranking	18 módulos analizados; 2 clasificados con riesgo; margen máximo 1,312.	CP01 / OG. Límite: Clasificación ≠ defectos reales; margen no es probabilidad.
EVV06 — UI04 Exportación y gráfico	Botón de descarga y distribución visual 16 no positivos / 2 positivos.	CP01 / CP04 (flujo normal). Límite: No acredita por sí sola sanitización de fórmulas de CP04.
EVV07 — UI05 Historial	Ejecución nueva E6 completada, 18 módulos, 2 positivos, UUID y hashes; entradas E7 previas conservadas.	CP05 / OG. Límite: E7 es historial anterior; no debe confundirse con el modelo operativo.
EVV08 — UI06 Guía y limitaciones	La aplicación advierte que no extrae métricas desde código y que el score es un margen no calibrado.	O8 / OG. Límite: No demuestra extracción efectiva de 21 métricas desde un repositorio.
EVV09 — CSV exportado visto en Excel	Ranking descargado con 18 registros, prioridad, ID, clase, score e interpretación.	CP01 / CP04 (exportación positiva). Límite: No contiene ID de fórmula adversaria; Excel muestra CSV en columna A por configuración de importación.
EVV10 — CSV de entrada visto en Excel	Archivo de ejemplo con encabezados y 18 filas de métricas.	CP01. Límite: Excel no descompone automáticamente las columnas con delimitador coma en la captura.
EVV11 — Plantilla CSV vista en Excel	Encabezados esperados en la plantilla vacía.	CP01 (preparación). Límite: Plantilla en blanco no acredita procesamiento de datos.

Ruta de cada archivo y hash SHA-256: paquete T2_EVIDENCIA_VISUAL_PI13_PI14_10NOV2026.zip / capturas_originales/ e INDICE_CAPTURAS.csv.

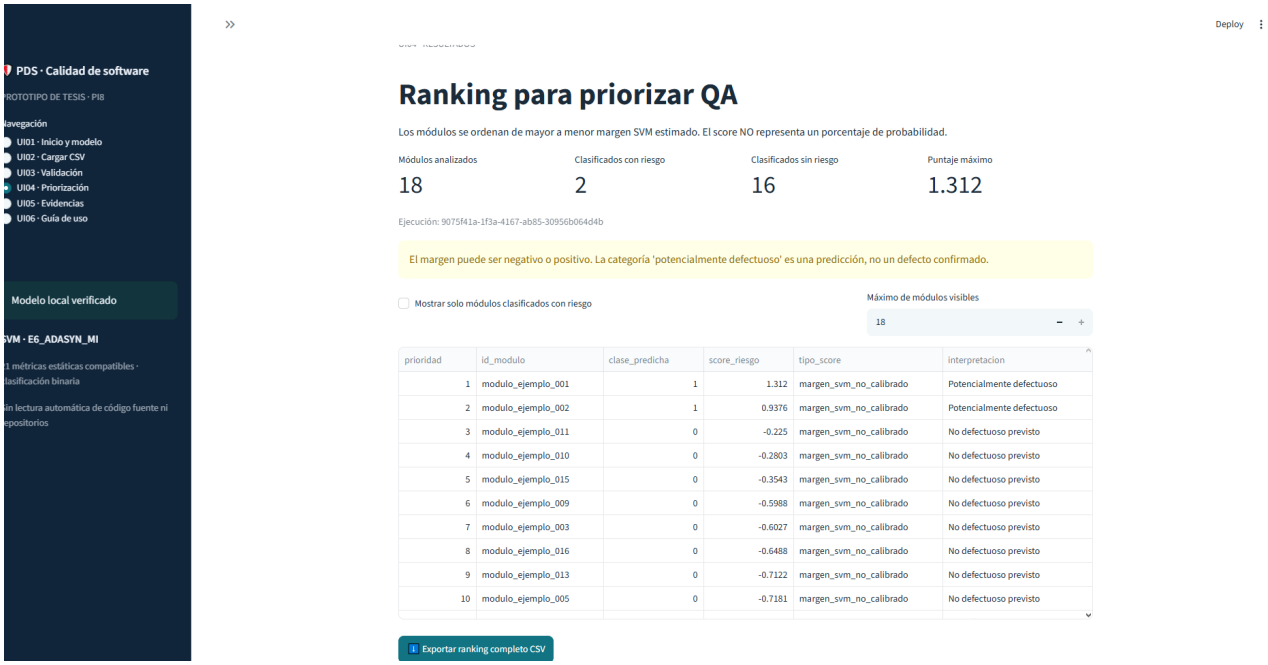
Registro visual de apoyo — no sustituye el análisis estadístico

EVV04 — UI03 Validación: CSV válido: 18 módulos, 21 métricas, 0 faltantes; SHA-256 del archivo.



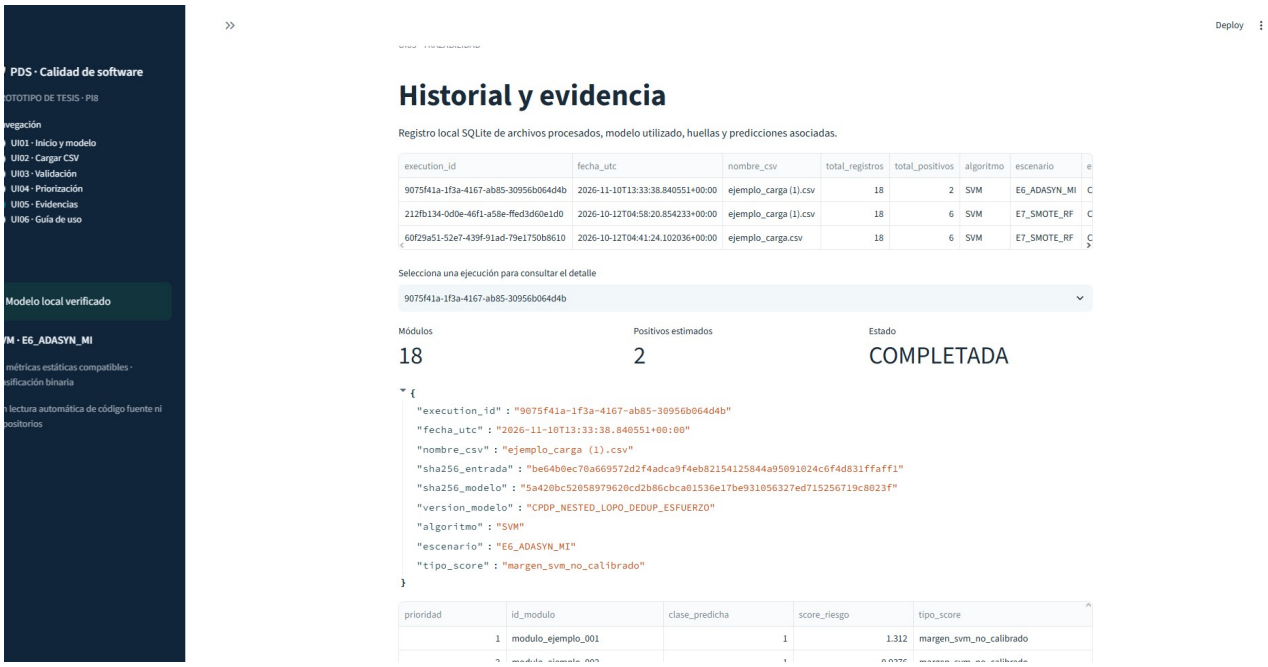
Alcance: No es una prueba de rechazo de CSV inválido.

EVV05 — UI04 Ranking: 18 módulos analizados; 2 clasificados con riesgo; margen máximo 1,312.



Alcance: Clasificación ≠defectos reales; margen no es probabilidad.

EVV07 — UI05 Historial: Ejecución nueva E6 completada, 18 módulos, 2 positivos, UUID y hashes; entradas E7 previas conservadas.



Alcance: E7 es historial anterior; no debe confundirse con el modelo operativo.